
# 原始文档格式:

[<offset1>]<text1>[<offset2>]<text2>[<offset3>]<text3>... ...

### BWT:



# 原始文档

[8]Computers in industry[9]Data compression[10]Integration[11]Big data indexing

# 经过 BWT 之后

agsan1[[1[[]]]]nngy1890ttDdr nnttrdineBzzzxstooiooiiiIcCiimmgpetrseuaanuasdper

#### RLB:

黄色表示连续重复出现 3 次以上的字符 用 1 开头的字节表示,剩余 7 bits 表示(重复次数-3) 1000 0000 表示重复 3 次 1000 0111 表示重复 10 次

如果 7 bits 不够表示重复次数,重复次数超过 2<sup>7</sup>7 次,用多个 1 开头的字节表示重复次数。 20,000 is represented as 19,997, in binary 1 0011100 0011101 and it will be divided into 3 bytes accordingly: 10011101 10011100 10000001.

# RLB 之后

agsan1[[1[[]♦nngy1890ttDdr nnttrdineB ♦xstooiooi♦IcCiimmgpetrseuaanuasdper

#### 任务

在 RLB 文件中进行对于原始文档的搜索

搜索: "in"

返回: [8]Computers in industry

[11]Big data indexing

#### 过程


重点:用RLB文件创建Ctable和Occurrence table

C[i] 储存 number of chars alphabetically less than i


Occ[m,n] 储存 number of occurrences of char m at the n th char of the file

比如 BNNAAA 
$$Occ[A, 1] = 0$$
  $Occ[A, 4] = 1$   $Occ[A, 6] = 3$ 

#### 用 Backward Search



### Backward search of the pattern 'si'



得到 First 和 Last 两个数字

Last – First + 1 就是 "in" 总共在原始文件出现的次数

从 First 到 Last 进行 loop 操作

比如 29 - 33

29 放到 C table 得到 第一个原始 char 和这个 char 目前出现的次数(第 n 个这个 char) 放到 Occ table, 得到第 n 个这个 char 在 L 里面的序数

又把序数放到 C table ······

直到遇到'['为止,得到 in 的前半段原始字符,后半段操作同理反过来

两边相加,得到一条完整的 record:

[8]Computers in industry

30 放进 C table…

得到所有 5 个 records, 排序排重输出答案